```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings

warnings.filterwarnings(action='ignore')

In [2]: train = pd.read_csv("./train.csv")
test = pd.read_csv("./test.csv")
```

1. 간단한 전처리 및 데이터 분포 확인

1.1 데이터 차원 및 중복행 확인


```
In [4]:
          print(train.shape) #training set 약 10만행
          print(test.shape) #test set 약 25000행
          (103976, 13)
          (25995, 12)
 In [5]: train.head(3)
             country description designation price province region_1 region_2 taster_name taster_twitter_handle
                                                                                                               title
 Out[5]:
                                                                                                                        variety
                                                                                                                                  win
                                                                                                            Banrock
                      Possibly a
                                                                                                             Station
                      little sweet.
                                                            South
                                                 Australia
                                                                                  Joe
                                                                                                               2006
                                                                                                                                 Bann
                                                                                                 @JoeCz Chardonnay
          0 Australia
                        this is a
                                      NaN
                                            5.0
                                                          Eastern
                                                                      NaN
                                                                                                                    Chardonnay
                                                   Other
                                                                             Czerwinski
                                                                                                                                  Stat
                                                          Australia
                          soft,
                                                                                                              (South
                        easyg...
                                                                                                           Eastern..
                                                                                                           Cellier des
                         A soft
                                                                                                           Dauphins
                       almost off
                                                                                                               2015
                                                                                                                               Cellier
                                                   Rhône
                                                          Côtes du
              France
                        dry wine
                                   Réserve
                                           12.0
                                                                      NaN
                                                                            Roger Voss
                                                                                              @vossroger
                                                   Valley
                                                           Rhône
                                                                                                            Réserve
                                                                                                                                Dauph
                     that is full in
                                                                                                              Rosé
                           th..
                                                                                                            (Côtes ...
                        Generic
                                                                                                          Esperanza
                       white-fruit
                                    Estate
                                                                                                          2013 Estate
                                                 Northern
                                                                               Michael
                                                                                                                       Verdejo-
                                            9.0
               Spain
                                   Grown &
                                                           Rueda
                                                                      NaN
                                                                                             @wineschach
                                                                                                                               Esperai
                                                                                                            Grown &
                      aromas of
                                                   Spain
                                                                             Schachner
                                                                                                                          Viura
                      peach and
                                    Bottled
                                                                                                             Bottled
                        apple ...
                                                                                                           Verdejo-...
 In [6]:
          train.columns
          Out[6]:
                dtype='object')
 In [7]:
         train.duplicated().sum() #모든 칼럼이 동일한 행이 약 6405행->의미가 없으므로 제거
In [111]:
          #결측치 비율 확인
          train.isnull().sum()/train.shape[0]*100
                                      0.049195
          country
          description
                                      0.000000
          designation
                                     28.854885
                                      6.976458
          price
                                      0.049195
          province
                                      16.342971
          region_1
          region 2
                                      61.042728
          taster name
                                      20.624981
          taster_twitter_handle
                                      24.433489
          title
                                      0.000000
                                      0.001025
          variety
                                      0.000000
          winerv
                                      0.000000
          points
          dtype: float64
```

- 약 61%로 높은 결측치 비율을 보이는 region_2 column은 제외하는 것이 타당해보인다
- designation, taster_name, taster_twitter_handle 등은 각 칼럼의 특성을 확인한 이후 삭제 혹은 모델 사용 여부를 결정하기로 한다

```
In [16]: #taster_name과 taster_twitter_handle 간 매칭 확인
train[(train['taster_name'].isna())&train['taster_twitter_handle'].notna()].shape

#taster name은 결측치이지만, 트위터 아이디가 결측치가 아닌 경우는 존재하지 않음, 즉 최소한 taster name이 기록된 항에만 트위터
```

```
Out[16]: (0, 12)
In [66]: train.drop("title", axis=1, inplace=True)
         #train.drop("region_2", axis=1, inplace=True)
In [19]: train.groupby("taster_name")['taster_twitter_handle'].nunique()
Out[19]: taster_name
         Alexander Peartree
                              0
         Anna Lee C. Iijima
                              0
         Anne Krebiehl MW
         Carrie Dykes
                              0
         Christina Pickard
                              1
         Fiona Adams
                              1
         Jeff Jenssen
         Jim Gordon
                              1
         Joe Czerwinski
         Kerin O'Keefe
         Lauren Buzzeo
                              1
         Matt Kettmann
         Michael Schachner
                              1
         Mike DeSimone
         Paul Gregutt
                              1
         Roger Voss
                              1
         Sean P. Sullivan
         Susan Kostrzewa
                              1
         Virginie Boone
         Name: taster_twitter_handle, dtype: int64
          • 모든 taster에 대해 고유한 트위터 아이디는 하나이므로 taster_twitter_handle은 삭제해도 무방
In [20]: train.drop('taster_twitter_handle', axis=1, inplace=True)
         1.2 변수의 분포 확인
In [21]: #price 변수 분포
         train['price'].describe()
        count
                  90764.000000
                     35.652021
         mean
         std
                     43.356430
                      4.000000
         min
         25%
                     17.000000
         50%
                     25.000000
         75%
                     42.000000
         max
                  3300.000000
         Name: price, dtype: float64
          • 최솟값이 3, 평균이 35, q3가 42이지만 max 값이 3300인점에서 이상치가 다수 존재한다는 점을 예측할 수 있다.
In [24]: plt.figure(figsize=(10,5))
         sns.distplot(train['price'])
         plt.show()
         print("Skewness : %.3f"%train['price'].skew())
         print("Kurtosis : %.3f"%train['price'].kurtosis())
           0.025
           0.020
```




Skewness : 19.033 Kurtosis : 862.744

• price 변수의 distplot이 매우 왜곡되어 있고, 왜도 및 첨도도 정규분포의 가정을 위해 적합하지 않음을 알 수 있다.

```
In [26]: plt.figure(figsize=(10,5))
```

```
sns.distplot(np.log(train['price']))
plt.show()

print("Skewness : %.3f"%np.log(train['price']).skew())
print("Kurtosis : %.3f"%np.log(train['price']).kurtosis())
```



Skewness: 0.614 Kurtosis: 0.817


• 과하게 높은 와인의 가격을 이상치로 생각하기보다, 와인 산업의 특성상 높은 가격이 책정된 이유가 있을 것이라 판단해 이상치 제거가 아닌 log 변환을 하게 되는 경우 distplot과 왜도 및 첨도가 모두 정상적인 분포를 보임을 확인할 수 있다. 이에 모델 학습에서는 원본 데이터에서 이상치를 제거한 데이터와 로그 변환을 한 데이터를 모두 사용하여 성능을 비교하는 것이 가능할 것이다

```
#target(=points변수) 분포 확인
         train['points'].describe()
         count
                  97571.000000
Out[27]:
                      88.444497
                      3.082897
         std
         min
                      80.000000
         25%
                      86.000000
         50%
                     88.000000
         75%
                     91.000000
         max
                     100.000000
         Name: points, dtype: float64
```

• 타겟값인 포인트 변수의 경우 표준편차가 상당히 적고, 최솟값이 80점 이상이므로 모든 평점이 80~100점 사이에 위치함을 알 수 있다.

```
In [30]: plt.figure(figsize=(10,5))
    sns.distplot(train['points'])
    plt.show()

print("Skewness : %.3f"%train['points'].skew())
    print("Kurtosis : %.3f"%train['points'].kurtosis())
```



Skewness: 0.047 Kurtosis: -0.334

- points 변수의 displot과 왜도, 첨도 모두 정상적 범주의 분포를 보임을 확인할 수 있다.
- points 변수의 distplot에서 확인할 수 있는 또 다른 점은, points 변수가 연속형 자료이긴 하지만 이산적인 분포를 보이고 있다는 점이다. 즉 소수점 자리가 존재하거나 80~100점 사이 모든 점수에 대해 점수가 존재하는게 아니라 몇몇의 정수 점수만 사용되고 있으며 이는 다른 변수와 평점 간 상관성을 살펴볼 때 points 변수에 대한 boxplot을 그려볼 여지가 존재함을 의미한다

2.1 price와 points 변수의 관계성

500

1000

```
In [32]: plt.figure(figsize=(10,5))
plt.scatter(train['price'], train['points'])
plt.show()


100.0
97.5
95.0
92.5
90.0
87.5
85.0
82.5
80.0
```

```
In [33]: plt.figure(figsize=(10,5))
  plt.scatter(np.log(train['price']), train['points'])
  plt.show()
```

2500

3000

2000



1500

• price 변수에 로그 변환을 진행한 후에 이를 points 변수와의 산점도로 표시해보면 훨씬 강한 양의 상관관계가 관찰됨을 확인할 수 있다

2.2 description의 길이와 points 간의 상관성

```
In [38]: #전체 데이터 중 같은 taster가 같은 description을 내린 비율
print(train.duplicated(subset=['description', 'taster_name'], keep=False).sum()/train.shape[0]*100)

0.04099578768281559

In [39]: #taster와 description이 같은 데이터에 대해, 평점도 같은 비율
subset=train[train.duplicated(subset=['description', 'taster_name'], keep=False)]
subset.groupby(['taster_name', 'description'])['points'].nunique().sum()/train.shape[0]*100

Out[39]: 0.03279663014625247
```

• 두 가지 자료의 비율을 고려할 때, taster가 해당 와인에 남기는 description은 각 와인에 대한 고유적 특성이 충분히 반영되었다고 판단할 수 있다. 이에 descrition을 points와 연관지어 생각해보기 위해 좋은 와인에는 더 긴 리뷰를 남겼을 것이라 가정하고 EDA를 진행


```
In [49]: train['length'] = train['description'].apply(lambda x : len(str(x).split(" "))) #description 길이 추가 train = pd.merge(train, train.groupby('taster_name')['length'].mean(), how='left', on='taster_name') #train 데이, train.rename(columns={'length_x':'length', 'length_y':'length_mean'}, inplace=True ) #병합 과정에서 생긴 열 이름 수 train['length_ratio'] = train['length']/train['length_mean']

train['length_ratio'].describe()
```

```
77447.000000
          count
Out[49]:
                        1.000000
          mean
                        0.254319
                        0.073093
          min
                        0.825597
          25%
          50%
                        0.976644
          75%
                        1.147569
                        2.933435
          max
```

Name: length_ratio, dtype: float64


```
plt.figure(figsize=(10,5))
In [50]:
         sns.distplot(train['length_ratio'])
         plt.show()
         print("Skewness : %.3f"%train['length_ratio'].skew())
         print("Kurtosis : %.3f"%train['length_ratio'].kurtosis())
```




Skewness: 0.575 Kurtosis: 1.022

- 각 행에 남겨진 description의 길이를 새로운 칼럼으로 추가해줬다.
- '좋은 와인에는 상대적으로 긴 리뷰를 남길것이다'를 가설로 채택했지만, taster마다 description의 길이에 대한 경향성이 다를 것이므 로 각 taster 당 평균 리뷰 길이를 계산한 후 각 행의 descrition에 대해 나누어줬다.
- 그렇게 계산된 length_ratio는 최솟값 0.07부터 2.93의 최댓값을 가지며 distplot과 왜도 첨도 모두 정상적 범주 내에 존재한다.

```
fig, axes = plt.subplots(figsize=(16,5), ncols=2)
axes[0].scatter(train['length_ratio'], train['points'])
axes[0].set_xlabel("length_ratio")
axes[0].set_ylabel("points")
sns.boxplot(train['points'], train['length_ratio'], ax=axes[1])
axes[1].set_xlabel("points distribution")
axes[1].set_ylabel("length_ratio")
plt.show()
```





- 리뷰를 남긴 리뷰어의 평균 리뷰 길이 대비 해당 와인의 리뷰 길이와 평점간 관계를 확인해보기 위해 length_ratio를 x축, points를 y축 으로 하는 산점도와 points를 x축, length_ratio를 y축으로 하는 boxplot을 그려보았다.
- 좌측 산점도에서는 약간의 양의 상관성이 있는 것처럼 보이지만 유의미한 차이를 확인하기가 힘들다
- 하지만 우측의 boxplot을 살펴보면 평점이 높아질수록 length_ratio의 중간값이 점점 상승하고 있는 것을 확인할 수 있으며 각 평점 별 quantile 역시 동시에 상승하고 있는 것을 확인할 수 있다.
- 즉, 높은 평점이 매겨진 와인은 상대적으로 긴 리뷰 글자수 비율을 보인다는 점을 확인할 수 있다.


```
        points
        points
        length_ratio

        points
        1.000000
        0.489781

        length_ratio
        0.489781
        1.000000
```

2.3 taster name 별 평점 분포

```
In [59]: train.taster_name.value_counts()
         #총 19명의 taster가 존재. 22, 6개를 기록한 두 명의 리뷰어를 제외하면 대부분 100건 이상을 진행
                               19290
         Roger Voss
Out[59]:
         Michael Schachner
                                11335
         Kerin O'Keefe
                                 7960
                                 7236
         Paul Gregutt
         Virginie Boone
                                7053
         Matt Kettmann
                                 4702
         Joe Czerwinski
                                3864
         Sean P. Sullivan
                                 3637
         Anna Lee C. Iijima
                                 3312
                                3033
         Jim Gordon
         Anne Krebiehl MW
                                2680
         Lauren Buzzeo
                                 1351
         Susan Kostrzewa
                                 817
         Mike DeSimone
                                 383
         Jeff Jenssen
                                 362
         Alexander Peartree
                                 299
         Carrie Dykes
                                  105
         Fiona Adams
                                  22
         Christina Pickard
         Name: taster name, dtype: int64
In [61]: index = train.groupby('taster_name').mean()['points'].sort_values(ascending=False).index
         plt.figure(figsize=(10,5))
         sns.boxplot(train.taster_name, train.points, order=index)
         plt.xticks(rotation=90)
         plt.show()
           100.0
            97.5
            95.0
```



• quantile 및 이상치를 고려했을 때 어느 정도의 변동성은 존재하지만 리뷰어별로 median 값이 유의미한 경향성을 보이고 있음을 확인 할 수 있다.

2. 4country와 평점 분포

```
In [103...
country=pd.DataFrame(train.value_counts('country'), columns = ['count'])
country['ratio'] = country['count']/country.values.sum()*100

country[:20]
```


```
count
                          ratio
    country
             40984
             16642 17.064692
     France
       Italy
             14604
                     14.974929
      Spain
               4890
                      5.014202
   Portugal
               4323
                      4.432800
       Chile
               3401
                      3.487382
  Argentina
               2875
                      2.948023
     Austria
               2447
                      2.509152
   Australia
               1777
                      1.822134
               1638
                      1.679604
   Germany
                      1.070517
New Zealand
               1044
South Africa
               1040
                      1.066415
                376
                      0.385550
      Israel
    Greece
                352
                      0.360940
    Canada
                185
                      0.189699
                106
                      0.108692
   Bulgaria
                      0.105616
   Hungary
                103
   Romania
                 86
                      0.088184
   Uruguay
                 77
                      0.078956
                      0.070753
     Turkey
                 69
```

Out[103]:

• 설명 : 소수 국가가 많은 비율을 차지한다, 이는 province 피쳐의 존재가 필요할 수 있다는 반증

```
index = train.groupby('country').mean()['points'].sort_values(ascending=False).index

plt.figure(figsize=(10,5))
sns.boxplot(train.country, train.points, order=index)
plt.xticks(rotation=90)
plt.show()
```



• country와 평점 간 boxplot 역시 median 값이 유의미한 경향성을 띄고 있음을 확인할 수 있음

variety 분포

```
Out[70]: Pinot Noir
                                      10036
                                       8825
         Chardonnay
         Cabernet Sauvignon
                                       7139
         Red Blend
                                       6685
         Bordeaux-style Red Blend
                                       5222
         Chardonnay-Riesling
                                          1
         Biancale
                                          1
         Thrapsathiri
                                          1
         Aidani
                                          1
         Gragnano
         Name: variety, Length: 676, dtype: int64
In [79]: min_index = train['variety'].value_counts()[train['variety'].value_counts().values > 100].index
In [87]:
         top_list = train[train['variety'].isin(min index)].groupby("variety").mean()['points'].sort values(ascending=Fa
         bottom_list = train[train['variety'].isin(min_index)].groupby("variety").mean()['points'].sort_values(ascending
In [105... top list
          variety
Out[105]:
          Sangiovese Grosso
                               90.566901
          Nebbiolo
                               90.323460
          Blaufränkisch
                               90.120000
          Grüner Veltliner
                               90.047521
          Port
                               89.857700
          Tinta de Toro
                               89.718750
          Champagne Blend
                               89.661366
                               89.447804
          Riesling
          Pinot Noir
                               89.418095
                               89.318211
          Syrah
          Name: points, dtype: float64
In [100_ bottom_list
          variety
Out[100]:
          Torrontés
                              85.494845
                              85.747863
          Garnacha
          Moscato
                              86.140741
          Pinot Grigio
                              86.224592
          Verdejo
                              86.336493
          Prosecco
                              86.402174
          Carmenère
                              86.590164
                              86.790440
          Rosé
          Montepulciano
                              86.850299
          Portuguese White
                             86.928324
          Name: points, dtype: float64
         province=pd.DataFrame(train.value counts('province'), columns = ['count'])
In [110...
         province['ratio'] = province['count']/province.values.sum()*100
         province[:20]
```

count ratio province California 27287 27.980066 Washington 6487 6.651764 Bordeaux 4525 4.639931 Tuscany 4380 4.491248 Oregon 4028 4.130308 Burgundy 3040 3.117213 Northern Spain 2825 2.896753 Piedmont 2814 2.885473 Mendoza Province 2475 2.537863 Veneto 2038 2.089763 **New York** 2019 2.070281 Alsace 1819 1.865201 Northeastern Italy 1596 1.636537 Loire Valley 1388 1.423254 Sicily & Sardinia 1333 1.366857 Champagne 1226 1.257139 Southwest France 1127 1.155625 South Australia 1013 1.038729

province와 평점의 관계성

1007

982

1.032577

1.006942


Southern Italy


Douro

```
In [131. #최소 와인 생산 갯수가 100개 이상인 province에 대해 분석
min_index_province = train['province'].value_counts()[train['province'].value_counts().values > 100].index

top_list = train[train['province'].isin(min_index_province)].groupby("province").mean()['points'].sort_values(a
#최소 와인 생산 갯수가 100개 이상인 province 중 평점 상위 20개 지역
bottom_list = train[train['province'].isin(min_index_province)].groupby("province").mean()['points'].sort_value
#최소 와인 생산 갯수가 100개 이상인 province 중 평점 하위 20개 지역

In [133. plt.figure(figsize=(10,5))
sns.boxplot(train[train['province'].isin(top_list.index)]['province'], train[train['province'].isin(top_list.inorder = top_list.sort_values(ascending=True).index)
plt.xticks(rotation=90)
plt.show()
```





• 평균 평점 상, 하위 20개 province에 대해 각각 평점의 boxplot을 plotting. x축의 province 나열 순서는 평균 평점 순이지만 상,하위 그래 프 모두에서 province 별 유의미한 차이는 발견되지 않음

*country, province 별 평점 분포 시각화

Loading [MathJax]/jax/output/CommonHTML/fonts/TeX/fontdata.js

1) 기본적인 전처리

- 중복된 데이터가 존재하고, description과 같은 변수만 중복된 경우 추가적인 확인 필요
- taster_name 칼럼과 taster_twitter_handle 칼럼이 1대1 대응
- 결측치를 포함하고 있는 행들이 있고, region_2의 결측치 비율이 큼


```
In [9]: # twitter id와 taster name이 일대일 대응하는지 확인
        df.groupby(['taster_name', 'taster_twitter_handle']).size()
Out[9]: taster_name
                          taster_twitter_handle
        Anne Krebieh∣ MW
                                                    2937
                          @AnneInVino
        Christina Pickard @winewchristina
        Fiona Adams
                          @bkfiona
                                                      23
        Jeff Jenssen
                           @worldwineguys
        Jim Gordon
                          @gordone_cellars
        Joe Czerwinski
                                                    4089
                          @JoeCz
        Kerin O' Keefe
                           @kerinokeefe
                                                    1428
        Lauren Buzzeo
                          @laurbuzz
        Matt Kettmann
                                                    5109
                           @mattkettmann
        Michael Schachner @wineschach
                                                   12026
                                                     425
        Mike DeSimone
                           @worldwineguvs
                                                   7673
        Paul Gregutt
                           @paulgwine
        Roger Voss
                          @vossroger
                                                   20536
                                                    3950
        Sean P. Sullivan
                          @wawinereport
        Susan Kostrzewa
                          @suskostrzewa
        Virginie Boone
                           @vboone
        dtype: int64
```

```
In [12]: df[df['description'].duplicated()].index

Out[12]: Int64Index([ 24798,  31067,  33270,  38558,  47705,  48829,  49512,  55976,  63279,  68952,  70422,  79643,  85389,  87262,  90848,  95434,  95441,  97075,  98038,  98695, 101386],  dtype='int64')
```


1) 기본적인 전처리 - 중복 데이터 제거

- 전체가 중복된 데이터는 제거
- 만약 description 행만이 중복되었다면, 해당하는 데이터는 행을 각각 확인하여 오기 여부 판단



1) 기본적인 전처리 - twitter 칼럼 제거, 결측치 추정

- twitter id 칼럼과 region_2 칼럼은 제거
- 결측치는 확인을 통해 바람직하게 추정할 수 있는 경우 대체 region_1 칼럼의 일부 정보, winery, taster 등




Portugal	4323
Chile	3401
Argentina	2875
Austria	2447
Australia	1777
Germany	1638

Portugal	4323
Chile	3401
Austria	2447
Germany	1638


2) EDA - Univariate Visualization

- 변수들 각각에 대하여 분포를 확인하기 위한 작업
- province의 집중도와 price의 right-skewed된 형태 등 특징적인 지점 확인






2) EDA - Vibariate Visualization



2) EDA - Vibariate Visualization

• EDA 목적: 점수의 기댓값 최대화, 분산(리스크) 최소화 항목 및 조합을 찾아보자



In [52]:	df[df.country == 'England']											
Out [52] :		country	designation	price	province	region_1	taster_name	title	variety	winery	points	
	1116	England	Rosé Bella	85.0	England	England	Anne Krebiehl MW	Bride Valley Vineyard 2014 Rosé Bella Sparklin	Sparkling Blend	Bride Valley Vineyard	94	
	1446	England	Classic Cuvée	50.0	England	England	Anne Krebiehl MW	Hoffmann & Rathbone 2013 Classic Cuvée Sparkli	Sparkling Blend	Hoffmann & Rathbone	91	
	4442	England	Brut	50.0	England	England	Anne Krebiehl MW	Camel Valley 2012 Brut Sparkling (England)	Sparkling Blend	Camel Valley	89	
	7308	England	Cuvée Brut	40.0	England	England	Anne Krebiehl MW	Wiston Estate Winery 2010 Cuvée Brut Sparkling	Sparkling Blend	Wiston Estate Winery	91	
	7948	England	Fitzrovia Rosé	42.0	England	England	Anne Krehiehl MW	Ridgeview Estate 2013 Fitzrovia Rosé	Sparkling Blend	Ridgeview Estate	89	

n [53] : ut [53] :	df[df.	f[df.province == "Südburgenland"]													
]:		country	designation	price	province	region_1	taster_name	title	variety	winery	points				
	3447	Austria	Perwolff	79.0	Südburgenland	Austria	Anne Krebiehl MW	Krutzler 2012 Perwolff Blaufränkisch (Südburge	Blaufränkisch	Krutzler	95				
	45793	Austria	Steinberg	35.0	Südburgenland	Austria	Anne Krebiehl MW	Jalits 2012 Steinberg Red (Südburgenland)	Red Blend	Jalits	93				

In [57]: df[df.winery == "Cayuse"] Out [57] : designation price province region_1 taster_name title variety winery points country Cayuse 2013 Walla Armada Sean P. Armada Vineyard 670 US 95.0 Washington Walla 94 Syrah Cayuse Vineyard Sullivan Syrah (Walla Valley (WA) Walla.. Cayuse 2010 Walla Bordeaux-Flying Pig Red Paul Gregutt 878 US Flying Pig 85.0 Washington Walla style Red Cayuse 95 (Walla Walla Valley (WA) Blend Walla Cayuse 2011 En En Cerise 75.0 Oregon Paul Gregutt Syrah Cayuse 947 Walla Cerise Vineyard Vineyard Valley (OR) Syrah (Walla Wa... Walla Cayuse 2013 Cailloux Sean P. 1306 US 70.0 Washington Walla Cailloux Vineyard Viognier Cayuse Vineyard Sullivan Valley (WA) Viognier (Walla ... Walla Cayuse 2014 God God Only Sean P. Oregon Red Blend Cayuse 2276 97.0 Walla Only Knows Red 93 Sullivan Knows Valley (OR) (Walla Walla Va., Cayuse 2014 Edith Edith Rosé Walla Sean P. Rosé Armada 92837 Armada 50.0 Washington Walla Grenache Cayuse 91 Sullivan Vineyard Valley (WA) Vineyard Grenach.. Cayuse 2012 En En Walla Sean P. Chamberlain 98235 75.0 Washington Walla US Chamberlain Syrah Cayuse 95 Sullivan Vineyard Syrah Vineyard Valley (WA) Cayuse 2014 Walla Armada Sean P. Armada Vineyard 99513 US Walla 93 Syrah Cayuse Vineyard Sullivan Syrah (Walla Valley (OR) Cayuse 2012 Walla Wallah Wallah Sean P. Wallah Wallah 100539 Walla Syrah Cayuse Special #4 Sullivan Special #4 Syrah Valley (WA) (Wa... Walla Cayuse 2014 Cailloux Sean P. 101666 75.0 Washington Walla 91 Cailloux Vineyard Viognier Cayuse Vineyard Sullivan Valley (WA) Viognier (Walla ..

65 rows × 10 columns

- 데이터 확인 작업은 시각화를 통해 확인했던 points와 의미가 있어보이는 데이터를 직접 확인해보 았다.
 - 지정한 칼럼 이외의 칼럼에 공통적인 값이 있는지 확인
 - 정보의 신뢰도를 위해 해당하는 칼럼의 수 확인
- 이를 통해 체크해둔 의미 있는 변수들 중 일부를 제거하고, 추가적인 확인 사항을 체크
 - country = England: taster가 모두 동일하고, variety가 Sparkling Blend에 집중
 - designation = Barrel Sample: taster가 모두 동일하고, variety 동일, 모두 France산
 - winery = Cayuse/Betz Family/Gramercy: country가 모두 US로 동일하고, region_1 유사,
 taster는 두 명으로 축소, variety는 'Syrah'에 집중

• country = England: taster가 모두 동일하고, variety가 Sparkling Blend에 집중

```
In [60]: df.points.describe()
Out[60]: count
                  97162.000000
                     88.447860
         mean
                      3.084275
         std
                     80.000000
         min
         25%
                     86.000000
         50%
                     88.000000
         75%
                     91.000000
                    100.000000
         Name: points, dtype: float64
In [61]: taster = ['Anne Krebiehl\xaOM\', 'Roger Voss', 'Sean P. Sullivan', 'Paul Gregutt']
         taster_points_mean = df.query(f'taster_name in {taster}').groupby('taster_name').mean().points
         taster_points_mean
Out[61]: taster_name
         Anne Krebieh∣ M₩
                             90.597981
         Paul Gregutt
                             89.084312
         Roger Voss
                             88.737077
         Sean P. Sullivan
                             88.724422
         Name: points, dtype: float64
```

• country = England: taster가 모두 동일하고, variety가 Sparkling Blend에 집중


- taster가 전체를 기준으로 보았을 때에도 상당히 점수를 잘 주는 taster에 해당함. 하지만 해당 taster가 세 개 국가를 평가하는데, 그 중 영국에 특히 높은 점수를 부여하는 것을 알 수 있음.
- Sparkling Blend는 점수의 기댓값이 평균 이하에 해당하는 variet임. 하지만, 이 variety가 특히 영국에서 높은 퍼포먼스를 보이고 있음.

3) EDA - 인사이트 정리

- winery: Cayuse, variety: Syrah
 - US라는 국가 제품의 리스크가 크고, 두 명의 taster 중 한 명은 다소 편차가 있는 평가를 부여하는 사람임. 하지만 variety Syrah의 경우 variety라는 변수 자체가 카테고리별 차이가 큰 변수는 아니지만, Syrah의 분포가 긍정적인 선택지일 것으로 보임. 특히 Cayuse winer와 결합되었을 때 퍼포먼스가 좋음.
- · country: England, variety: Sparkling Blend
 - 평가하는 taster가 가장 점수를 잘 주는 taster이자 영국 제품에 호의적인 taste임(Austria, France, England와 비교했을 때). 또한, Sparkling Blend라는 variety는 평균 이하의 기댓값을 받고 있지만 영국에서 좋은 퍼포먼스를 내고 있음.
- · designation: Barrel Sample
 - taste가 점수의 편차가 다소 크기 때문에 리스크를 감수할 필요가 있고, variet나 countr에 대해서도 인상적인 특징이 보이지 않아서 3순위로 고려할 항목일 것으로 생각된다.


3) EDA - 인사이트 보완

• 영국과 Sparkling Blend variety의 결합은 효과가 있는가?



3) EDA - 인사이트 보완

• Cayuse winery와 Syrah의 결합이 효과가 있는가?



3) EDA - 인사이트 정리 2

- · winery: Cayuse, variety: Syrah
 - Syrah라는 variety, Cayuse라는 winery 각각이 좋은 퍼포먼스를 내고 있을 뿐만 아니라, Cayuse 내에서 보더라도 Syrah가 가격 측면에서도, point 측면에서도 와인 생산자 입장에서는 좋은 선택지가 될 것으로 보임.
- country: England, variety: Sparkling Blend
 - England라는 국가의 점수대가 높고, Sparkling Blend라는 variety가 지배적이며, 해당 variety는 England에서 유독 높은 점수를 받고 있음. 하지만, England 내부적으로 보았을 때에는 Sparkling Blend를 선택하는 것이 최고의 선택지는 아닐 것으로 판단됨.
- · designation: Barrel Sample
 - 모든 변수에 있어서 무난한 리스크와 점수를 받을 수 있는 선택지.

1. Linear Regression

목차

- 1. 데이터 전처리
- 2. 선형회귀 모델 적합
- price: 기본 스케일, NaN value drop
- price: 기본 스케일, 평균으로 NaN value 채우기
- price: log 스케일, NaN value drop
- price: log 스케일, 평균으로 NaN value 채우기
- 3. Feature Selection
- 값이 10개 미만인 변수 None으로 대체
- 값이 10개 미만인 변수 None으로 대체+VIF Factor가 100 이상인 변수 삭제
- VIF Factor가 100 이상인 변수 삭제
- province 칼럼 제거 ((***진행중***))

1. 데이터 전처리

```
train_df.drop(columns = ['taster_twitter_handle', 'title', 'designation', 'region_1', 'region_2'], inplace=True)
train df['description length'] = train df.description.str.len()
mean_length = train_df.groupby('taster_name').mean()
mean_length.rename(columns={'description_length':'mean_length'}, inplace=True)
mean length = mean length.loc[:, 'mean length']
train_df = pd.merge(train_df, mean_length, how='left', on='taster_name')
train df['length ratio'] = train df['description length']/train df['mean length']
train_df.drop(columns=['description', 'winery', 'description_length', 'mean_length'], inplace=True)
drop_index = train_df[train_df.isna().sum(axis=1) > 3].index
train_df.drop(index=drop_index, inplace=True)
normal_train_df = train_df.copy()
log_train_df = train_df.copv()
log_train_df['price'] = np.log(train_df['price'])
```

1. 데이터 전처리 - 범주형:get_dummies()

```
normal train = pd.DataFrame()
for col in ['country', 'province', 'taster_name']:
    encoding_table = pd.get_dummies(normal_train_df[col], prefix=col)
    normal_train = pd.merge(normal_train, encoding_table, left_index=True, rightLindex=True, how='outer')
normal train.head(3)
                                                                                country_Bosnia
    country Argentina country Armenia country Australia country Austria
                                                                                           and country Brazil country Bulgaria co
                                                                                   Herzegovina
normal_train = pd.merge(normal_train, normal_train_df[['price', 'length_ratio', 'points']],
                     left index=True, right index=True, how='outer')
normal_train.head(3)
     taster name Mike taster name Paul taster name Roger taster name Sean taster name Susan taster name Virginie
                                                                                                                 price length_ratio points
            DeSimone
                                                              P. Sullivan
                                                                                                           Boone
                              Gregutt
                                                                                  Kostrzewa
nner
                                                   Voss
                                                                                                                            0.438881
                                                                                                                                         83
log_train = normal_train.copy()
                                                                       0
                                                                                         0
                                                                                                                   12.0
                                                                                                                            0.751700
                                                                                                                                         85
 log_train['price'] = log_train_df['price']
 log_train.head(3)
                                                                       0
                                                                                          0
                                                                                                                            0.808542
```

print('상수 값:', mlr.intercept_)

-6.74725734e-01 1.48778915e-01 8.04939106e-01 4.18548376e+11 1.56452276e-01 -1.36738205e+00 -5.87050303e+00 -5.18917531e-01 2.57018086e-01 -1.62502261e+00 2.08121239e+00 2.90661907e+00

• 1) price normal scale & null value drop

```
drop_index = normal_train[normal_train.isna().sum(axis=1)>0].index
normal_drop_df = normal_train.drop(index=drop_index)

normal_drop_x = normal_drop_df.loc[:, :'length_ratio']
normal_drop_y = normal_drop_df.loc[:, 'points']

x_train, x_test, y_train, y_test = train_test_split(normal_drop_x, normal_drop_y, train_size=0.8, test_size=0.2, random_state = 77)

# 모델 적합
mlr = LinearRegression()
mlr.fit(x_train, y_train)

LinearRegression()

print('회귀계수 값:', mlr.coef_)
```

• 1) price normal scale & null value drop

```
# summary
model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
model.summary()
                    OLS Regression Results
  Dep. Variable:
                  points
                                     R-squared:
                                                   0.488
     Model:
                  OLS
                                  Adj. R-squared: 0.484
                                     F-statistic:
     Method:
                  Least Squares
                                                   142.1
      Date:
                  Sat, 01 Oct 2022 Prob (F-statistic): 0.00
                                   Log-Likelihood: -1.3384e+05
      Time:
                  01:40:00
No. Observations: 61756
                                                   2.685e+05
                                        AIC:
  Df Residuals: 61344
                                        BIC:
                                                   2.722e+05
    Df Model:
                  411
 Covariance Type: nonrobust
                                                                                   0.9751
                                                    std err
                                                                   P>|t| [0.025
                                            coef
                                                                                  78.904
                                         78.2329
                                                   0.342
                                                            228.546 0.000 77.562
                  const
```

```
0.373
country_Argentina
                                        0.266
                                                 -0.560 0.575 -0.671
                              -0.1492
country_Armenia
                                                                       2.108
                              -0.0074
                                        1.079
                                                 -0.007 0.995 -2.122
country Australia
                                                        0.000 0.624
                                                                       1.909
                             1.2666
                                        0.328
 country_Austria
                             0.5650
                                        0.383
                                                1.474 0.140 -0.186
                                                                       1.316
```

Train set 적합

```
y_train_predict = mlr.predict(x_train)
r_squared = r2_score(y_train, y_train_predict)
print('Variance score(R-square): {0:.3f}'.format(r_squared))
```

Variance score(R-square): 0.482

test set 적합

```
y_test_predict = mlr.predict(x_test)
test_r_squared = r2_score(y_test, y_test_predict)
print('Variance score(R-square): {0:.3f}'.format(test_r_squared))
```

Variance score(R-square): 0.467

• 2) normal scale & fill null value by mean

```
normal_mean_df = normal train.copv()
normal_mean_df.price = normal_train.price.fillna(normal_train.price.mean())
normal_mean_df = normal_train.fillna(0)
normal_mean_x = normal_mean_df.loc[:, :'length_ratio']
normal mean y = normal mean df.loc[:, 'points']
x_train, x_test, y_train, y_test = train_test_split(normal_mean_x, normal_mean_y, train_size=0.8, test_size=0.2, random_state = 77)
#모델 적합
mlr = LinearRegression()
mlr.fit(x_train, y_train)
```

LinearRegression()

• 2) normal scale & fill null value by mean

```
# summary
model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
model.summary()
                    OLS Regression Results
  Dep. Variable:
                                    R-squared:
                 points
                                                  0.401
     Model:
                  OLS
                                  Adj. R-squared: 0.398
                                     F-statistic:
    Method:
                 Least Squares
                                                  132.5
                 Sat, 01 Oct 2022 Prob (F-statistic): 0.00
      Date:
      Time:
                 01:40:06
                                  Log-Likelihood: -1.8922e+05
No. Observations: 83180
                                        AIC:
                                                  3.793e+05
  Df Residuals:
                                        BIC:
                                                  3.832e+05
                 82761
    Df Model:
                  418
Covariance Type: nonrobust
```

```
y_train_predict = mlr.predict(x_train)
r_squared = r2_score(y_train, y_train_predict)
print('Variance score(R-square): {0:.3f}'.format(r_squared))

Variance score(R-square): 0.401

y_test_predict = mlr.predict(x_test)
r_squared = r2_score(y_test, y_test_predict)
print('Variance score(R-square): {0:.3f}'.format(r_squared))

Variance score(R-square): 0.367
```

	coef	std err	t	P> t	[0.025	0.975]
const	85.9303	0.440	195.458	0.000	85.069	86.792
country_Argentina	0.0820	0.309	0.265	0.791	-0.524	0.688
country_Armenia	-0.4334	0.866	-0.501	0.617	-2.131	1.264
country_Australia	1.0868	0.390	2.788	0.005	0.323	1.851
country Austria	1.0314	0.446	2.310	0.021	0.156	1.907

• 3) price log scale & drop null value

```
drop_index = log_train[log_train.isna().sum(axis=1)>0].index
log_drop_df = log_train.drop(index=drop_index)
log_drop_x = log_drop_df.loc[:, :'length_ratio']
log drop y = log drop df.loc[:, 'points']
x_train, x_test, y_train, y_test = train_test_split(log_drop_x, log_drop_y, train_size=0.8, test_size=0.2, random_state = 77)
#모델 적합
mlr = LinearRegression()
mlr.fit(x_train, y_train)
LinearRegression()
print('회귀계수 값:', mlr.coef_)
print('상수 값:', mlr.intercept_)
```

• 3) price: log scale & drop null value

```
# summarv
model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
model.summary()
                    OLS Regression Results
  Dep. Variable:
                  points
                                     R-squared:
                                                   0.572
     Model:
                  OLS
                                  Adj. R-squared: 0.569
                  Least Squares
                                     F-statistic:
     Method:
                                                   199.7
                  Sat, 01 Oct 2022 Prob (F-statistic): 0.00
      Date:
                                   Log-Likelihood: -1.2827e+05
      Time:
                  01:40:11
No. Observations: 61756
                                        AIC:
                                                   2.574e+05
   Df Residuals:
                  61344
                                        BIC:
                                                   2.611e+05
    Df Model:
                  411
 Covariance Type: nonrobust
```

coef

73.4623

0.1340

0.2414

1.2179

0.4541

-0.3127

const country_Argentina

country_Armenia

country Australia

country_Austria

country Bosnia and Herzegovina

std err

0.315

0.243

0.986

0.300

0.350

0.704

P>|t| [0.025

0.582 -0.343

0.807 - 1.691

0.000 0.631

0.195 -0.232

233.487 0.000 72.846

-0.444 0.657 -1.692

0.550

0.245

4.066

1.297

0.975]

74.079

0.611

2.174

1.805

1.141

1.066

```
y_train_predict = mlr.predict(x_train)
r_squared = r2_score(y_train, y_train_predict)
print('Variance score(R-square): {0:.3f}'.format(r_squared))

Variance score(R-square): 0.572

y_test_predict = mlr.predict(x_test)
test_r_squared = r2_score(y_test, y_test_predict)
print('Variance score(R-square): {0:.3f}'.format(test_r_squared))

Variance score(R-square): -5931847847196464128.000
```

LinearRegression()

• 4) price: log scale & fill null value by mean

```
log_mean_df = log_train.copy()
log_mean_df.price = log_train.price.fillna(log_train.price.mean())

log_mean_df = log_mean_df.fillna(0)

log_mean_x = log_mean_df.loc[:, :'length_ratio']
log_mean_y = log_mean_df.loc[:, 'points']

x_train, x_test, y_train, y_test = train_test_split(log_mean_x, log_mean_y, train_size=0.8, test_size=0.2, random_state = 77)

# 모델 적합
mlr = LinearRegression()
mlr.fit(x_train, y_train)
```

country Bulgaria

• 4) price: log scale & fill null value by mean

0.572

-0.137 0.891 -1.201

-0.0787

```
# summary
                                                                                 v train predict = mlr.predict(x train)
model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
                                                                                 r squared = r2 score(y train, y train predict)
model.summarv()
                                                                                 print('Variance score(R-square): {0:.3f}'.format(r_squared))
                  OLS Regression Results
 Dep. Variable:
                                 R-squared: 0.502
               points
                                                                                 Variance score(R-square): 0.502
     Model:
                OLS
                              Adj. R-squared: 0.500
    Method:
                                 F-statistic:
               Least Squares
                                            199.6
               Sat, 01 Oct 2022 Prob (F-statistic): 0.00
     Date:
                                                                                 y_test_predict = mlr.predict(x test)
                              Log-Likelihood: -1.8153e+05
     Time:
               01:40:17
                                                                                 test_r_squared = r2_score(y_test, y_test_predict)
No. Observations: 83180
                                             3.639e+05
                                   AIC:
                                                                                 print('Variance score(R-square): {0:.3f}'.format(test_r_squared))
  Df Residuals:
               82761
                                   BIC:
                                             3.678e+05
   Df Model:
Covariance Type: nonrobust
                                                                                 Variance score(R-square): -129336472568534712320.000
                                                                         0.975]
                                       coef
                                                            P>|t| [0.025
               const
                                    79.2839
                                             0.403
                                                     196.673 0.000 78.494
                                                                         80.074
          country_Argentina
                                    0.3865
                                             0.282
                                                     1.370 0.171 -0.166
                                                                         0.939
          country_Armenia
                                    -0.0781
                                             0.789
                                                           0.921 -1.626
                                                                         1.469
          country_Australia
                                             0.355
                                                     3.049
                                                           0.002 0.387
                                                                         1.780
                                    1.0837
           country_Austria
                                    0.7014
                                             0.407
                                                           0.085 -0.096
                                                                         1.499
                                                    1.723
   country_Bosnia and Herzegovina
                                    -0.2924
                                             0.785
                                                     -0.373 0.709 -1.830
                                                                         1.245
           country_Brazil
                                             0.580
                                                     -2.018 0.044 -2.308
                                                                         -0.034
                                    -1.1711
```

1.043

• 1) 값이 10개 미만인 변수 None으로 대체

```
train_df.drop(columns=['variety'], inplace=True)
```

country_Argentina

country_Australia

country_Austria

• 1) 값이 10개 미만인 변수 None으로 대체

0.587 -0.295 0.521

0.000 0.751 1.711

-1.4174 0.676 -2.097 0.036 -2.742 -0.093

```
\times train, \times test, y train, y test = train_test_split(log_drop_\times, log_drop_y, train_size=0.8, test_size=0.2, random_state = 77).
# 모델 적합
mlr = LinearRegression()
                                                                 v train predict = mlr.predict(x train)
mlr.fit(x_train, y_train)
                                                                 r squared = r2 score(y train, y train predict)
    # summarv
                                                                 print('Variance score(R-square): {0:.3f}'.format(r_squared))
   model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
    model.summarv()
                                                                 Variance score(R-square): 0.571
                   OLS Regression Results
     Dep. Variable: points
                              R-squared: 0.571
                 OLS
                             Adj. R-squared: 0.569
        Model:
       Method:
                Least Squares
                               F-statistic:
                                       324.3
                                                                 y_test_predict = mlr.predict(x test)
        Date:
                 Sat, 01 Oct 2022 Prob (F-statistic): 0.00
                             Log-Likelihood: -1.2840e+05
        Time:
                 01:40:32
                                                                 test r squared = r2 score(v test, v test predict)
    No. Observations: 61756
                                         2.573e+05
                                 AIC:
                                                                 print('Variance score(R-square): {0:.3f}'.format(test_r_squared))
      Df Residuals: 61503
                                 BIC:
                                         2.596e+05
       Df Model:
                 252
    Covariance Type: nonrobust
                                                                 Variance score(R-square): 0.559
                                            P>|t| [0.025 0.975]
                                       293.693 0.000 72.979 73.960
              const
```

• 2) 값이 10개 미만인 변수 None으로 대체+VIF Factor가 100 이상인 변수 삭제

```
log drop train = pd.DataFrame()
for col in ['country', 'province', 'taster_name']:
    encoding_table = pd.get_dummies(train_df[col], prefix=col)
    log_drop_train = pd.merge(log_drop_train, encoding_table,
                              left_index=True, right_index=True, how='outer')
log drop train = pd.merge(log drop train, train df[['price', 'length ratio', 'points']],
                          left_index=True, right_index=True, how='outer')
drop_index = log_drop_train[log_drop_train.isna().sum(axis=1)>0].index
log_drop_df = log_drop_train.drop(index=drop_index)
log_drop_x = log_drop_df.loc[:, :'length_ratio']
log drop y = log drop df.loc[:, 'points']
vif = pd.DataFrame()
vif['VIF Factor'] = [variance inflation factor(log drop x.values, i) for i in range(log drop x.shape[1])]
vif['features'] = log_drop_x.columns
drop_cols = vif[vif['VIF Factor'] > 100].features.values
log_train_df.drop(columns=drop_cols)
```

• 2) 값이 10개 미만인 변수 None으로 대체+VIF Factor가 100 이상인 변수 삭제

```
x_{train}, x_{test}, y_{train}, y_{test} = train_{test_{split}}(log_drop_x, log_drop_y, train_{size}=0.8, test_{size}=0.2, train_{test_{size}}
# 모델 적합
mlr = LinearRegression()
                                                          v train predict = mlr.predict(x train)
mlr.fit(x_train, y_train)
                                                           r_squared = r2_score(y_train, y_train_predict)
                                                          print('Variance score(R-square): {0:.3f}'.format(r_squared))
 # summary
 model = sm.OLS(v train. sm.add constant(x train)).fit()
 model.summarv()
                                                          Variance score(R-square): 0.543
               OLS Regression Results
  Dep. Variable: points
                          R-squared: 0.543
    Model:
             OLS
                        Adj. R-squared: 0.542
    Method:
             Least Squares
                          F-statistic: 381.1
                                                          v test predict = mlr.predict(x test)
             Sat, 01 Oct 2022 Prob (F-statistic): 0.00
     Date:
                                                          test r squared = r2 score(y test, y test predict)
     Time:
             01:59:48
                         Log-Likelihood: -1.3031e+05
 No. Observations: 61756
                            AIC:
                                    2.610e+05
                                                          print('Variance score(R-square): {0:.3f}'.format(test_r_squared))
  Df Residuals: 61563
                            BIC:
                                    2.628e+05
   Df Model:
 Covariance Type: nonrobust
                                                          Variance score(R-square): 0.536
                                        P>|t| [0.025 0.975]
           const
                                        0.000 -4.215 -2.367
        country_Brazil
                        -3.2910 0.471 -6.983
```

• 3) VIF Factor가 100 이상인 변수 삭제

```
x_train, x_test, y_train, y_test = train_test_split(log_drop_x, log_drop_y, traih_size=0.8, test_size=0.2, random_state = 77)
#모델 적합
mlr = LinearRegression()
                                                      v train predict = mlr.predict(x train)
mlr.fit(x train, v train)
                                                      r_squared = r2_score(y_train, y_train_predict)
model = sm.OLS(y train, sm.add constant(x train)).fit()
                                                      print('Variance score(R-square): {0:.3f}'.format(r_squared))
model.summarv()
              OLS Regression Results
                                                      Variance score(R-square): 0.527
 Dep. Variable: points
                         R-squared: 0.527
   Model:
            OLS
                        Adj. R-squared: 0.527
                         F-statistic:
                                   2221.
   Method:
            Least Squares
            Sat, 01 Oct 2022 Prob (F-statistic): 0.00
    Date:
                                                      v test predict = mlr.predict(x test)
    Time:
            01:59:49
                        Log-Likelihood: -1.3136e+05
                                   2.628e+05
No. Observations: 61756
                            AIC:
                                                      test r squared = r2 score(y test, y test predict)
  Df Residuals: 61724
                            BIC:
                                   2.631e+05
   Df Model:
                                                      print('Variance score(R-square): {0:.3f}'.format(test_r_squared))
Covariance Type: nonrobust
                       coef std err
                                      P>|t| [0.025 0.975]
                                                      Variance score(R-square): 0.524
      country Brazil
     country Bulgaria
                     0.1075 0.267 0.402
                                     0.687 -0.416 0.631
```

• 3) VIF Factor가 100 이상인 변수 삭제

```
x_train, x_test, y_train, y_test = train_test_split(log_drop_x, log_drop_y, train_size=0.8, test_size=0.2, random_state = 77)
                              # summary
#모델 적합
                              model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
mlr = LinearRegression()
                              model.summarv()
mlr.fit(x_train, y_train)
                                                 OLS Regression Results
                                Dep. Variable:
                                                                           0.543
                                              points
                                                               R-squared:
                                   Model:
                                              OLS
                                                             Adj. R-squared: 0.542
                                   Method:
                                              Least Squares
                                                               F-statistic:
                                                                            381.1
                                    Date:
                                              Sat, 01 Oct 2022 Prob (F-statistic): 0.00
                                    Time:
```

 Time:
 01:59:48
 Log-Likelihood:
 -1.3031e+05

 No. Observations:
 61756
 AIC:
 2.610e+05

 Df Residuals:
 61563
 BIC:
 2.628e+05

Df Model: 192

Covariance Type: nonrobust

```
const 77.1845 0.048 1602.197 0.000 77.090 77.279
country_Brazil -3.2910 0.471 -6.983 0.000 -4.215 -2.367
country_Rulgaria -1.7289 0.714 -2.422 0.015 -3.128 -0.330
```

- 1) 값이 10개 미만인 변수 None으로 대체
- variance score(r^2) (Train) 0.571
- variance score(r^2) (Test) 0.559
- 2) 값이 10개 미만인 변수 None으로 대체+VIF Factor가 100 이상인 변수 삭제
- variance score(r^2) (Train) 0.543
- variance score(r^2) (Test) 0.536
- 3) VIF Factor가 100 이상인 변수 삭제
- variance score(r^2) (Train) 0.527
- variance score(r^2) (Test) 0.524

• 4) province 칼럼 제거, 모델 적합

```
drop cols = []
for col in log drop df.columns:
    if "province_" in col:
        drop cols.append(col)
log_drop_df.drop(columns=drop_cols, inplace=True)
log_drop_x = log_drop_df.loc[:, :'length_ratio']
log_drop_y = log_drop_df.loc[:, 'points']
x_train, x_test, y_train, y_test = train_test_split(log_drop_x, log_drop_y, train_size=0.8, test_size=0.2, random_state = 77)
#모델 적합
mlr = LinearRegression()
```

0.020 -0.708 -0.059

• 4) province 칼럼 제거, 모델 적합

```
# summary
model = sm.OLS(y_train, sm.add_constant(x_train)).fit()
model.summary()
                    OLS Regression Results
  Dep. Variable:
                 points
                                    R-squared:
                                                  0.527
                  OLS
     Model:
                                  Adj. R-squared: 0.527
     Method:
                  Least Squares
                                     F-statistic:
                                                  2221.
                  Sat, 01 Oct 2022 Prob (F-statistic): 0.00
      Date:
                  01:59:49
                                  Log-Likelihood: -1.3136e+05
      Time:
No. Observations: 61756
                                        AIC:
                                                  2.628e+05
  Df Residuals: 61724
                                        BIC:
                                                  2.631e+05
    Df Model:
Covariance Type: nonrobust
                                                      P>|t| [0.025 0.975]
                                 coef std err
                               77.0121 0.047 1648.431 0.000 76.921 77.104
             const
        country_Brazil
                               -2.8341 0.371 -7.641
                                                      0.000 -3.561 -2.107
       country Bulgaria
                               0.1075 0.267 0.402
                                                      0.687 -0.416 0.631
        country_Croatia
                               -1.5671 0.316 -4.958
                                                      0.000 -2.187 -0.948
        country_Greece
                                                      0.000 1.582 2.238
                               1.9098 0.167 11.409
       country_Hungary
                               -0.3503 0.257 -1.362
                                                      0.173 -0.855 0.154
```

-0.3834 0.165 -2.318

country_Israel

2. Decision Tree

목차

- 0. 데이터 전처리
- 1. 모델 적합
- 2. 모델 성능 개선(Grid search, random search)
- 3. 하이퍼파라미터 튜닝
- 4. 최적 모델 선택
- 5. 결과 예측

0. 데이터 전처리

• train, test 데이터 통합 후 전처리

```
#데이터 불러오기
train = pd.read_csv("train.csv")
test = pd.read_csv("test.csv")
#데이터 통합(onehotencoding 위해 통합)
tgt = pd.concat([train, test], ignore_index=True)
```

```
#중복값 제거
tgt = tgt.drop_duplicates()

#description 통해 새로운 변수들 생성

tgt['length'] =tgt['description'].apply(lambda x : len(str(x).split(" ")))
tgt = pd.merge(tgt, tgt.groupby('taster_name')['length'].mean(), how='left', on='taster_name')

tgt.rename(columns={'length_x':'length', 'length_y':'length_mean'}, inplace=True )
tgt['length ratio'] = tgt['length']/tgt['length mean']
```

0. 데이터 전처리 – feature selection

```
#모델링에 사용할 feature 선택
features = ['price', 'length', 'country', 'province', 'taster_name', 'variety', 'length_ratio']

categorical_columns = ['country', 'province', 'taster_name', 'variety']
num_columns = ['price', 'length', 'length_ratio']

#feature 중에 categorical variable 결축치 처리 (None으로 대체)
# categorical_columns = ['country', 'province', 'taster_name', 'variety']

tgt[categorical_columns] = tgt[categorical_columns].fillna('None')
```

	country	province	taster_name	variety
0	Australia	Australia Other	Joe Czerwinski	Chardonnay
1	France	Rhône Valley	Roger Voss	Rosé
2	Spain	Northern Spain	Michael Schachner	Verdejo-Viura
3	US	California	None	Cabernet Sauvignon
4	US	California	None	Pinot Noir

0. 데이터 전처리 – One Hot encoding

```
#categorical variables — OneHotEncoding 진행

from sklearn.preprocessing import OneHotEncoder

OH_encoder = OneHotEncoder(handle_unknown='ignore', sparse= False)

OH_cols_tgt = pd.DataFrame(OH_encoder.fit_transform(tgt[categorical_columns])) # 모든 categorical variable 대한 onehotencoding

OH_cols_tgt.index = tgt.index # 인텍스 복원

OH_cols_tgt.columns = OH_encoder.get_feature_names_out(categorical_columns) #column 명 복원
```

OH_cols_tgt

	country_Argentina	country_Armenia	country_Australia	country_Austria	country_Bosnia and Herzegovina	country_Brazil	country_Bulgaria	country_Canada	countr
0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
123165	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
123166	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
123167	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
122160	0.0	0.0	0.0	0.0	0.0	0.0	0.0	^ ^	

0. 데이터 전처리 - 연속형 변수 결측치

```
# feature 중에 numerical variable 처리

from sklearn.impute import SimpleImputer

num_tgt = tgt[num_columns]

my_imputer = SimpleImputer(strategy='mean') #평균으로 결측치 대체

# my_imputer = SimpleImputer(strategy='median')

imputed_num_tgt = pd.DataFrame(my_imputer.fit_transform(num_tgt), columns =num_tgt.columns)

imputed_num_tgt.index = num_tgt.index #기존의 index 복원

# 각각 결촉치 처리한 데이터 하나로 통합
```

alltogether = pd.concat([imputed_num_tgt, OH_cols_tgt, tgt['points']], axis = 1)

0. 데이터 전처리 - train, test set 구분

각각 결측치 처리한 데이터 하나로 통합 alltogether = pd.concat([imputed_num_tgt, OH_cols_tgt, tgt['points']], axis = 1)

		price	length	length_ratio	country_Argentina	country_Armenia	country_Australia	country_Austria	country_Bosnia and Herzegovina	country_Brazil	country_Bul
Ī	0	5.0	18.0	0.438726	0.0	0.0	1.0	0.0	0.0	0.0	
	1	12.0	31.0	0.825427	0.0	0.0	0.0	0.0	0.0	0.0	
	2	9.0	33.0	0.769747	0.0	0.0	0.0	0.0	0.0	0.0	
	3	29.0	40.0	1.000000	0.0	0.0	0.0	0.0	0.0	0.0	
	4	40.0	35.0	1.000000	0.0	0.0	0.0	0.0	0.0	0.0	
	123165	16.0	28.0	0 600011	0.0	0.0	0.0	0.0	0.0	0.0	

```
# points 점수의 유무를 기준으로 trainset, testset 구분
trainset = alltogether[alltogether.points.notnull()]
testset = alltogether[alltogether.points.isnull()]
```

1. 모델 적합

train, valid, test 셋 구분

```
x = trainset.drop('points', axis = 1).copv()
  y = trainset['points'].copy()
  \times_train, \times_valid, \times_train, \times_valid = train_test_split(\times, \times, train_size = 0.8, test_size = 0.2, random_state = 1)
from sklearn.tree import DecisionTreeRegressor
                                                                    features:['price', 'length', 'country', 'province', 'taster_name', 'variety', 'length_ratio']
from sklearn.metrics import mean squared error
                                                                     Max Depth: 5
from sklearn.metrics import mean absolute error
                                                                     MSE : 4.922829723963125
                                                                    RMSE: 2.2187450786341194
for n in [5, 10, 15]: #max_depth -> 10이 가장 결과 좋음
                                                                     R<sup>2</sup>: 0.48733372750003934
                                                                                              'country', 'province', 'taster_name', 'variety', 'length_ratio']
    #모델 적합
                                                                    Max Depth : 10
                                                                    MSE: 4.492795077928151
    model = DecisionTreeRegressor(random state=10, max depth=n)
                                                                    BMSF: 2.1196214468456747
    model.fit(x_train, y_train)
                                                                    R^2: 0.5321177788263374
                                                                    reatures:[price , length , 'country', 'province', 'taster_name', 'variety', 'length_ratio']
    #무텔 예측
                                                                     Max Depth: 15
    valid preds = model.predict(x valid)
                                                                     MSE : 4.717407259967713
                                                                     BMSE: 2.171959313607811
    #무델 평가
                                                                     R^2 : 0.5087265391164247
    print('features:{}'.format(features))
    print('Max Depth : {}'.format(n))
    print('MSE : {}'.format(mean_squared_error(y_valid, valid_preds)))
    print('RMSE: {}'.format(mean_squared_error(y_valid, valid_preds, squared=False)))
    print('R^2 : {}'.format(r2 score(v valid, valid preds)))
```

2. 모델 성능 개선 – Grid search

```
#Grid Search
                                                                                grid.best_params_
                                                                                {'max depth': 20,
from sklearn.model_selection import GridSearchCV
                                                                                 'max_leaf_nodes': 300,
from sklearn.metrics import accuracy score
                                                                                 'min_samples_leaf': 0.003,
                                                                                 'min samples split': 5}
import warnings
                                                                                grid.best score
warnings.filterwarnings("ignore")
                                                                                0.517257681472379
params = {
                                                                                #최적 모델 추천
     'max_depth': [10, 20, 50],
     'min_samples_split': [1, 5, 10, 50],
                                                                               y_pred = grid.predict(x_valid)
    'min_samples_leaf': [0.1, 0.03, 0.003],
                                                                                print("MSE: ", mean_squared_error(y_valid,y_pred))
     'max leaf nodes': [100, 200, 300],
                                                                                print("RMSE: ", (mean_squared_error(y_valid,y_pred))**0.5)
                                                                                print("MAE: ", mean_absolute_error(y_valid,y_pred))
                                                                               print('R^2(Score) : {}'.format(r2_score(y_valid, valid_preds)))
                                                                                MSE: 4.523538915640542
grid = GridSearchCV(DecisionTreeRegressor(random_state=10);
                                                                                BMSE: 2.126861282651161
                      params, scoring = r2', cv = 5, verbose = 3)
                                                                                MAE: 1.682450094593127
                                                                                R^2(Score): 0.5087265391164247
grid.fit(x train, y train)
```

2. 모델 성능 개선 – Random Search

```
random grid.best params
#Random Search
                                                                                         {'min samples split': 10,
                                                                                         'min_samples_leaf': 10,
from sklearn.model selection import RandomizedSearchCV
                                                                                         'max leaf nodes': 500,
                                                                                          'max depth': 40}
params = {'max_depth': [10, 15, 20, 40],
            'min_samples_split': [1, 5, 10],
                                                                                        random grid.best_score_
            'min_samples_leaf': [50, 25, 10, 1, 0.1, 0.003, 0.003],
                                                                                        0.5343913679896175
            'max_leaf_nodes': [300, 400, 500].}
                                                                                        #최적 모델 추천
                                                                                        y_pred = random_grid.predict(x_valid)
random_grid = RandomizedSearchCV(DecisionTreeRegressor(random_state=10),
                                       params, n_{jobs}=-1.
                                                                                        print("MSE: ", mean_squared_error(y_valid,y_pred))
                                                                                        print("RMSE: ", (mean_squared_error(y_valid,y_pred))**0.5)
                                       scoring='r2'.
                                                                                        print("MAE: ", mean_absolute_error(y_valid,y_pred))
                                       n iter=100)
                                                                                        MSF: 4.393722372024975
random grid.fit(x train, v train)
                                                                                        BMSE: 2.0961207913727145
                                                                                        MAE: 1.654189742179463
```

2. 모델 성능 개선 - 하이퍼파라미터 튜닝

• Grid Search 결과 추천 parameter 값 : {'max_depth': 20, 'max_leaf_nodes': 300, 'min_samples_leaf': 0.003, 'min_samples_split': 5}

MSE: 4.523538915640542 RMSE: 2.126861282651161 MAE: 1.682450094593127

R^2(Score): 0.5087265391164247

• Random Search 결과 추천 parameter 값 : 'min_samples_split': 10, 'min_samples_leaf': 10, 'max_leaf_nodes': 500, 'max_depth': 40}

MSE: 4.393722372024975 RMSE: 2.0961207913727145 MAE: 1.654189742179463

R^2(Score): 0.5343913679896175

-> 최종적으로 Random Search의 결과를 따르기로 결정

3. 최적 모델 적합

```
#최적 모델 적합
from sklearn.tree import DecisionTreeRegressor
from sklearn.metrics import mean squared error
from sklearn.metrics import mean_absolute_error
#무델 적합
model = DecisionTreeRegressor(random_state=10, min_samples_split=10, min_samples_leaf=10, max_leaf_nodes=500, max_depth=40)
model.fit(x_train, y_train)
#모델 예측
valid_preds = model.predict(x_valid)
#모델 평가
print('features:{}'.format(features))
print('MSE : {}'.format(mean_squared_error(y_valid, valid_preds)))
print('RMSE: {}'.format(mean_squared_error(y_valid, valid_preds, squared=False)))
print('R^2 : {}'.format(r2_score(y_valid, valid_preds)))
features:['price', 'length', 'country', 'province', 'taster_name', 'variety', 'length_ratio']
MSE: 4.393722372024975
BMSF: 2.0961207913727145
R^2 : 0.5424352664685824
```

4. 결과 예측

- Test set에 대한 데이터 전처리는 앞에서 완료
- 여기에서는 null 값으로 채워진 points column 만 삭제

```
from sklearn.tree import DecisionTreeRegressor
from sklearn.metrics import mean_squared_error
from sklearn.metrics import mean_absolute_error

model = DecisionTreeRegressor(random_state=10, min_samples_split=10, min_samples_leaf=10, max_leaf_nodes=500, max_depth=40)
model.fit(x_train, y_train)

#모텔 예측
test_pred = model.predict(testset)
```

결과를 파일로 저장 wine_prediction = pd.DataFrame({'id': testset.index, 'points': test_pred}) wine_prediction wine_prediction.to_csv('wine_point_prediction.csv', index=**False**)

3. 랜덤포레스트 회귀

목차

- 1. Pycaret을 활용하여 모델 간 성능비교
- 2. 모델 선택
- 3. 모델 적합
- 4. 하이퍼파라미터 튜닝
- 5. 시각화
- 6. 예측결과

0. input data

```
df.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 119988 entries, 0 to 119987
Data columns (total 7 columns):
                  Non-Null Count Dtype
   country
             119929 non-null <u>object</u>
    points
 2 price
3 province 119929 non-null object
                  95071 non-null object
4 taster_name
 5 variety
                  119987 non-null object
 6 wordent_ratio 119988 non-null float64
dtypes: float64(2), int64(1), object(4)
memory usage: 7.3+ MB
```

- (X) categorical: country, province, taster_name, variety
- (X) Numerical: price, wordcnt_ratio
- (Y) Target variable: points

Price: 결측치 평균 대체 후 로그스케일링 진행.

```
#1. train, test set 분리

[] data = df.sample(frac=0.8, random_state=786)
    data_unseen = df.drop(data.index)

    data.reset_index(drop=True, inplace=True)
    data_unseen.reset_index(drop=True, inplace=True)

print('Data for Modeling: ' + str(data.shape))
    print('Unseen Data For Predictions: ' + str(data_unseen.shape))
    ## 예측용 data 10%. 빼놓기

Data for Modeling: (95990, 7)
    Unseen Data For Predictions: (23998, 7)
```

- Train, test set를 각각 0.8:0.2로 분리

1. Pycaret을 활용하여 모델 간 성능비교

# pycare models()	tONH XF.	용 가능한 모델 목록	Reference	Turbo
ID				
lr		Linear Regression	sklearn.linear_modelbase.LinearRegression	True
lasso		Lasso Regression	sklearn.linear_modelcoordinate_descent.Lasso	True
ridge		Ridge Regression	sklearn.linear_modelridge.Ridge	True
en		Elastic Net	sklearn.linear_modelcoordinate_descent.Elast	True
lar		Least Angle Regression	sklearn.linear_modelleast_angle.Lars	True
llar	Lass	so Least Angle Regression	sklearn.linear_modelleast_angle.LassoLars	True
omp	Or	rthogonal Matching Pursuit	$sklearn. linear_model._omp. Or tho gonal Matching Pu$	True
br		Bayesian Ridge	sklearn.linear_modelbayes.BayesianRidge	True
ard	Automatio	Relevance Determination	sklearn.linear_modelbayes.ARDRegression	False
par	Pass	sive Aggressive Regressor	sklearn.linear_modelpassive_aggressive.Passi	True
ransac	Ra	andom Sample Consensus	sklearn.linear_modelransac.RANSACRegressor	False
tr		TheilSen Regressor	sklearn.linear_modeltheil_sen.TheilSenRegressor	False
huber		Huber Regressor	sklearn.linear_modelhuber.HuberRegressor	True
kr		Kernel Ridge	sklearn.kernel_ridge.KernelRidge	False
svm		Support Vector Regression	sklearn.svmclasses.SVR	False
knn		K Neighbors Regressor	$sklearn.neighbors_regression.KNeighborsRegressor$	True
dt		Decision Tree Regressor	sklearn.treeclasses.DecisionTreeRegressor	True
rf		Random Forest Regressor	$sklearn.ensemble._forest.RandomForestRegressor$	True
et		Extra Trees Regressor	sklearn.ensembleforest.ExtraTreesRegressor	True
ada		AdaBoost Regressor	$sklearn.ensemble._weight_boosting.AdaBoostRegr$	True
gbr	Gr	adient Boosting Regressor	sklearn.ensemblegb.GradientBoostingRegressor	True
mlp		MLP Regressor	sklearn.neural_networkmultilayer_perceptron	False
lightgbm	Light	Gradient Boosting Machine	lightgbm.sklearn.LGBMRegressor	True
dummy		Dummy Regressor	sklearn.dummy.DummyRegressor	True

→ 24개의 모델 간 비교 가능

```
models_used = ['Ir', 'dt', 'rf', 'ada', 'gbr', 'lightgbm']
models_not_used = [i for i in list(models().index) if i not in models_used]
```

→ 6개 모델 간 비교:

- → Linear Regression
- → Decision tree Regressor
- → Random Forest Regressor
- → Adaboost
- → Gradient Boosting Regressor
- → Light GBM

2. 모델 선택

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
rf	Random Forest Regressor	1.4730	4.1532	2.0379	0.5665	0.0228	0.0167	140.1630
lightgbm	ghtgbm Light Gradient Boosting Machine		4.2579	2.0634	0.5556	0.0231	0.0180	1.6520
gbr	Gradient Boosting Regressor	1.8190	5.2740	2.2965	0.4496	0.0257	0.0206	42.3220
ada	AdaBoost Regressor		6.1704	2.4839	0.3561	0.0278	0.0226	65.3010
dt	Decision Tree Regressor		7.1714	2.6777	0.2513	0.0300	0.0194	3.2960
lr	Linear Regression	3.1368	12606.4593	57.4863	-1322.3892	0.0657	0.0357	8.1740

- → R squared, RMSE 등 모든 값에서 Random Forest Regressor가 가장 성능이 높음을 알 수 있음.
- → Random Forest Regressor 선택

3. 모델 적합

#3. 모델 선택: random forest regressor

```
# random forest 모델 생성, 4 fold cross validation.
rf = create_model('rf', fold=4, verbose=True)
```

	MAE	MSE	RMSE	R2	RMSLE	MAPE
Fold						
0	1.5074	4.2585	2.0636	0.5539	0.0231	0.0171
1	1.4938	4.2214	2.0546	0.5616	0.0230	0.0169
2	1.5231	4.3170	2.0777	0.5525	0.0233	0.0173
3	1.5187	4.3586	2.0877	0.5416	0.0234	0.0172
Mean	1.5107	4.2889	2.0709	0.5524	0.0232	0.0171
Std	0.0113	0.0528	0.0127	0.0071	0.0001	0.0001

→ 시간상 cross validation fold 수를 4로 지정하고 진행(default=10)

4. 하이퍼파라미터 튜닝

#4. 모델 하이퍼파라미터 튜닝

• 소요시간이 너무 길어서 반복 수를 3으로(default=3) 지정하고 진행했는데 정확도가 기존 rf모델보다 낮게 나와서 실제로 쓰진 않음.


Tune the mode/
tuned_rf = tune_model(rf, n_iter = 3)

	MAE	MSE	RMSE	R2	RMSLE	MAPE
Fold						
0	1.9902	6.2073	2.4914	0.3532	0.0279	0.0226
1	1.9851	6.1811	2.4862	0.3495	0.0279	0.0225
2	2.0070	6.3964	2.5291	0.3306	0.0284	0.0228
3	1.9831	6.2009	2.4902	0.3578	0.0279	0.0225
4	1.9852	6.2472	2.4994	0.3508	0.0280	0.0225
5	2.0266	6.4425	2.5382	0.3452	0.0285	0.0230
6	1.9942	6.2738	2.5048	0.3404	0.0281	0.0227
7	1.9701	6.1211	2.4741	0.3431	0.0277	0.0223
8	1.9868	6.2475	2.4995	0.3507	0.0280	0.0225
9	1.9823	6.2537	2.5007	0.3483	0.0280	0.0225
Mean	1.9911	6.2572	2.5014	0.3470	0.0280	0.0226
Std	0.0148	0.0917	0.0183	0.0072	0.0002	0.0002


5. 결과 시각화 - 잔차

5.1. 잔차

plot_model(rf) # Train set에서는 94,1% 적합, Test set에서는 57.3% 적합 -> 과적합 발생한 것으로 해석 가능.




plot_model(rf, plot = 'error')



5. 결과 시각화 – Feature Importance

5.2. Feature Importance

```
# Feature Importance
plot_model(rf, plot='feature')
## Price, 리뷰 단어 수, 와인 종류(Pinot Noir, Chardonnay, Red Blend, Cabernet Sauvignon)이 기여도 높았음.
```



6. Points 예측

unseen_predictions = predict_model(rf, data=data_unseen)
unseen_predictions.head()

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE
0	Random Forest Regressor	1.4335	4.0152	2.0038	0.5775	0.0225	0.0163

	country	points	price	province	taster_name	variety	wordcnt_ratio	Label
0	US	87	2.564949	Michigan	Alexander Peartree	Riesling	0.879686	85.53
1	Spain	87	2.708050	Northern Spain	Michael Schachner	Tempranillo-Merlot	1.119600	86.88
2	Italy	87	2.772589	Sicily & Sardinia	Kerin O'Keefe	Frappato	0.826372	87.61
3	Germany	87	2.484907	Rheinhessen	Anna Lee C. lijima	Gewürztraminer	0.639772	87.33
4	US	87	3.526361	California	Virginie Boone	Cabernet Sauvignon	0.746400	88.07

관측값

예측값